

# Dimensionality Reduction

using 

FactoMineR & Factoextra

# Introduction to R

## Code Editor

## R console Terminal

The screenshot displays the RStudio IDE interface. The top-left pane shows a script editor with the following R code:

```
1 library(FactoMineR)
2 library(Factoshiny)
3
4 data(decathlon)
5
6 res = Factoshiny(decathlon)
7
8
9
10
```

The top-right pane shows the Environment pane with the following table:

Variable	Value
activeindPCAshiny	"black"
axe1PCAshiny	1
axe2PCAshiny	2
categPCAshiny	"magenta"
color_arrowInit	"active/supplementary"
color_pointInit	"active/supplementary"

The bottom-left pane shows the Console with the following output:

```
R 4.3.3 ~/  
plot.PCA(res.PCA, choix = var1)  
> library(Factoshiny)  
> data(decathlon)  
> res = Factoshiny(decathlon)  
  
Listening on http://127.0.0.1:6422  
  
Listening on http://127.0.0.1:6422  
Warning: Computation failed in `stat_bin()`.  
Caused by error in `bin_breaks_bins()`:  
! `bins` must be a whole number, not the number 8.2.  
  
> |
```

# Environment Variables History

# Plots Help Files

- Install and load library

```
> install.packages("ggplot2") # Install new library  
> library(ggplot2) # Load library
```

- Visualise documentation for a function or library

```
> ?mean # or help(mean)  
> help("PCA", package = "FactoMineR")  
> example(mean)
```

- Load preloaded datasets

```
> data(cars)  
> library(help = "datasets")  
> View(cars)
```

# R: Data Frames

---

A data frame is a table of data in R:

- each row = one individual (or observation),
- each column = one variable (or attribute),
- columns can be of different types (numeric, text, factor, etc.).

```
> class(cars)
> is.data.frame(cars)
```

```
> df = data.frame(
  Nom = c("Alice", "Bob", "Clara"),
  Age = c(23, 25, 22),
  Sexe = c("F", "M", "F")
)
```

# R: Manipulate Data Frames

---

```
> head(cars)

> summary(cars)

> head(mtcars)

> names(mtcars) # Show column names

> mtcars$hp <- NULL # Delete a column

> mtcars <- mtcars[-2,] # Delete a row

> mtcars$new_var <- 1:nrow(mtcars) # Add a column
```

## R: Read csv

- Example of csv file

```
Name; City; Sallary; Year
Alpha; Paris; 22000; 2023
Beta; Lyon; 69500; 2023
Gamma; Marseille; 33400; 2023
Delta; Paris; 12000; 2024
```

- Read csv file

```
data <- read.csv("ventes.csv", sep = ";", dec = ".", header = TRUE, row.names = 1)
```

Delimiter  
(eg. , or \t or ;)

Decimal  
separator  
(. or ,)

Whether the first  
line is columns  
names

Use first column  
as index

# TP1: R basics

---

1. Charger un dataset intégré
  1. Chargez le jeu de données **mtcars**.
  2. Visualiser les données sous forme de table.
  3. Affichez les 5 premières lignes et le résumé des variables.
2. Modifier le dataset
  1. Supprimez la colonne drat.
  2. Ajoutez une colonne prix avec des valeurs aléatoires entre 10000 et 40000.
  3. Supprimez la première ligne du tableau.
3. Ajouter une nouvelle ligne
  1. Créez une ligne avec vos propres valeurs et ajoutez-la à la fin.
4. Sauvegarder et réimporter
  1. Sauvegardez votre table CSV en utilisant write.csv (utiliser ?write.csv pour afficher l'aide.)
  2. Réimportez-la avec read.csv() et vérifiez les données.



# Dimensionality

# Reduction

using



# PCA using FactoMineR

---

- FactoMineR is an R package (developed by the team of François Husson) dedicated to multivariate exploratory data analysis. The main goal is to simplify complex multivariate analyses and make them accessible and interpretable.
- It provides functions for the most common multivariate methods, such as:
  - ◆ Principal Component Analysis (**PCA**)
  - ◆ Correspondence Analysis (**CA**)
  - ◆ Multiple Correspondence Analysis (**MCA**)
  - ◆ Hierarchical Clustering (**HCPC**)
  - ◆ and several extensions (**MFA**, **MFAmix**, etc.).
- FactoMineR automatically produces:
  - ◆ Tables of eigenvalues, contributions, and squared cosines ( $\cos^2$ )
  - ◆ Graphical outputs (individuals, variables, biplots)
  - ◆ Interpretation aids (which variables/individuals influence each axis)

# PCA using FactoMineR

---

- Load Library

```
> install.packages(c("FactoMineR", "factoextra"))  
> library(FactoMineR)  
> library(factoextra)
```

- Run PCA on USArrests dataset

```
> res.pca <- PCA(USArrests)
```




- Basic plots

```
> plot(res.pca, choix = "var") # Plot of variables  
> plot(res.pca, choix = "ind") # Plot of individuals
```

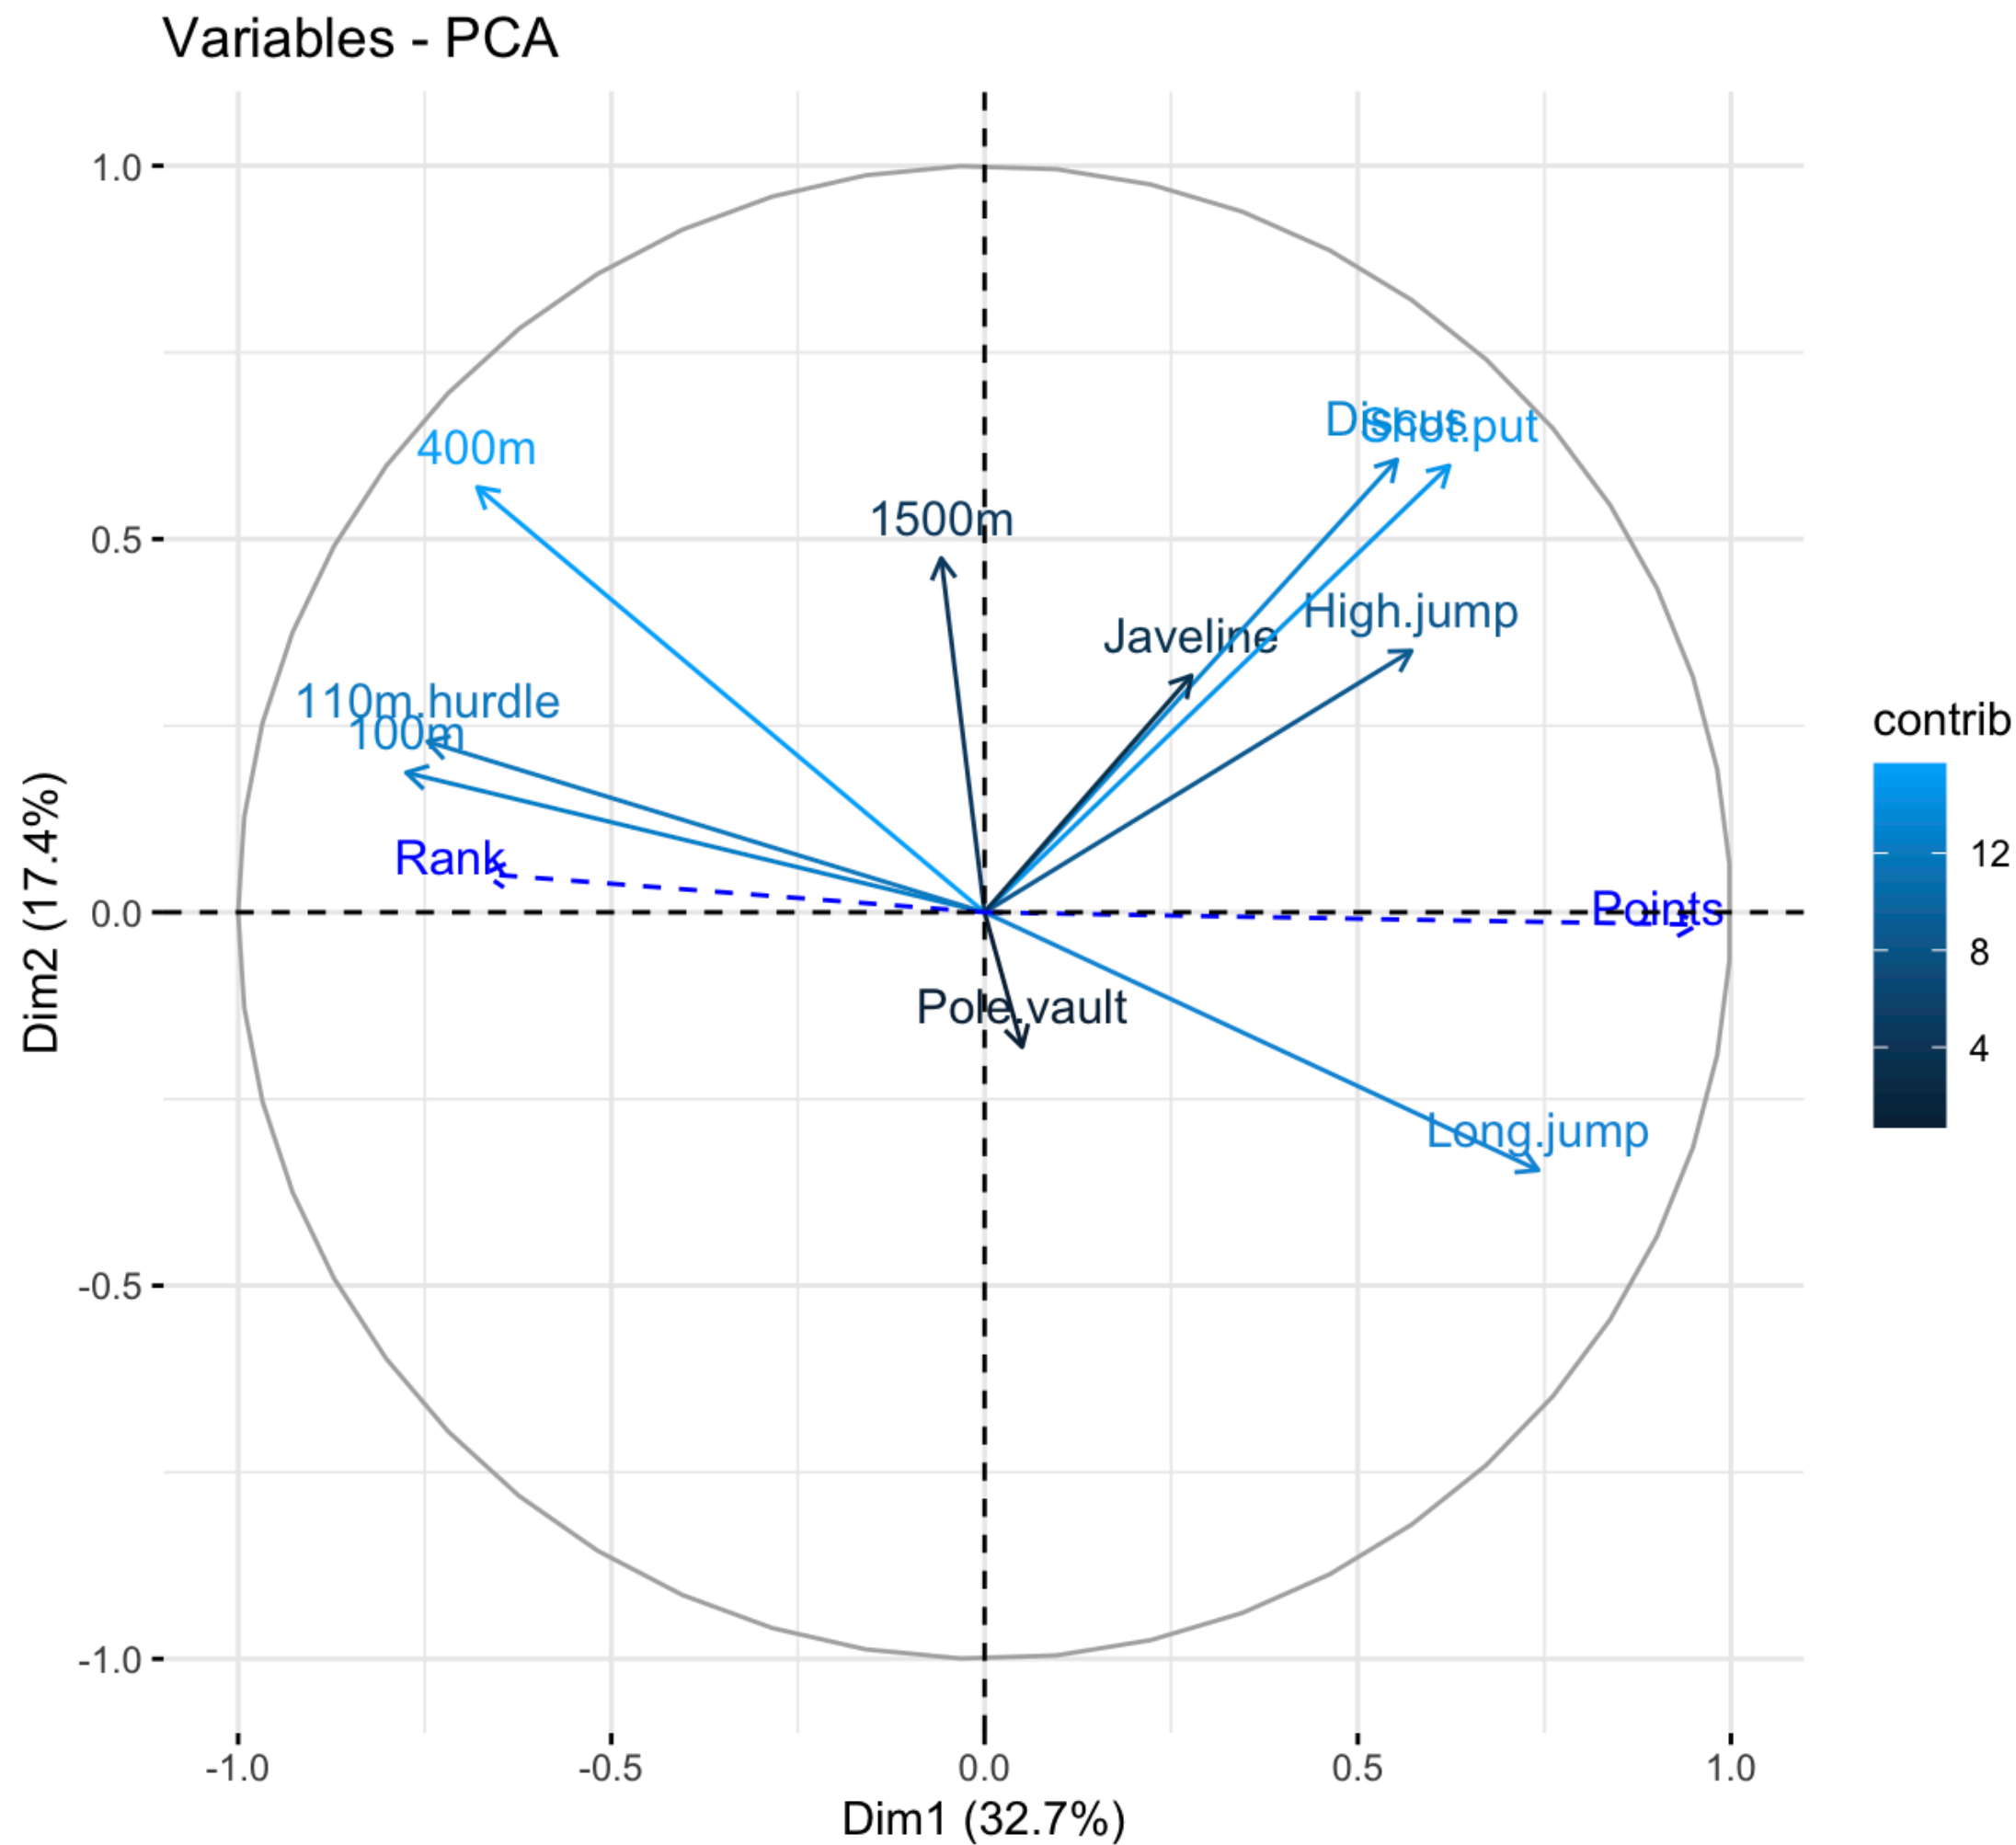
# PCA using FactoMineR and factoextra

- Use factoextra for better visualization

```
fviz_eig(res.pca, addlabels = TRUE, ylim = c(0, 50)) # Scree plot
fviz_pca_var(res.pca, col.var = "contrib")           # Variables
fviz_pca_ind(res.pca, col.ind = "cos2", gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"))
fviz_pca_biplot(res.pca, repel = TRUE)               # Biplot
```



# PCA using FactoMine: Variables plot interpretation



- ▶ Each arrow represents a quantitative variable.
- ▶ The **direction** and **length** of an arrow show how much that variable contributes to the **axes**. Longer arrows → better represented on the plane (higher  $\cos^2$ ).
- ▶ Variables close to the same axis are the ones that define that component the most.
- ▶ The angle between arrows indicates **correlation** between variables:
  - Small angle (close arrows) → strong positive correlation.
  - Opposite directions ( $180^\circ$ ) → strong negative correlation.
  - Perpendicular ( $90^\circ$ ) → very weak correlation.



**Objectif.** Réaliser une ACP sur les données decathlon. Les données portent sur des athlètes ayant participé à un décathlon (10 épreuves d'athlétisme). Chaque ligne correspond à un athlète, chaque colonne à une épreuve : 100m, longueur, poids, hauteur, 400m, 110m haies, disque, perche, javelot et 1500m. L'objectif est de comprendre comment ces épreuves sont reliées entre elles, quelles dimensions principales structurent la performance globale.

### 1. Préparation et exploration

- Sélectionner les variables quantitatives correspondant aux dix épreuves.
- Examiner la structure et le résumé statistique du jeu de données.
- Expliquer brièvement le type de variables et les unités mesurées.

### 2. Réaliser une ACP

- Effectuer une ACP sur les dix épreuves uniquement et considérer le reste en variables supplémentaires.
- Afficher le cercle des corrélations des variables avec FactoMineR avec factoextra.
- Identifier les variables fortement corrélées, ceux qui sont bien représentées, et ceux qui contribuent le plus aux deux premiers axes.
- Interpréter les deux premiers axes : que semble représenter le premier axe ? Que semble représenter le deuxième axe ?
- Repérer les grands groupes de variables et les types de performances qu'ils décrivent.