

Dimensionality Reduction

using 

FactoMineR & Factoextra

Introduction to R

Code Editor

R console Terminal

The screenshot displays the RStudio environment with three main panels:

- Source Panel (Top Left):** Shows the script `Data_init.R` with the following code:


```
1 library(FactoMineR)
2 library(Factoshiny)
3
4 data(decathlon)
5
6 res = Factoshiny(decathlon)
7
8
9
10
```
- Environment Panel (Top Right):** Shows the variable `x` with 41 observations of 13 variables. The values are:

Variable	Value
<code>activeindPCAshiny</code>	"black"
<code>axe1PCAshiny</code>	1
<code>axe2PCAshiny</code>	2
<code>categPCAshiny</code>	"magenta"
<code>color_arrowInit</code>	"active/supplementary"
<code>color_pointInit</code>	"active/supplementary"
- Console Panel (Bottom):** Shows the execution of the script:


```
R 4.3.3 ~ /
> library(Factoshiny)
> data(decathlon)
> res = Factoshiny(decathlon)

Listening on http://127.0.0.1:6422

Listening on http://127.0.0.1:6422
Warning: Computation failed in `stat_bin()`.
Caused by error in `bin_breaks_bins()`:
! `bins` must be a whole number, not the number 8.2.

>
```

A red dashed rectangle highlights the Environment and Console panels.

Environment Variables History

Plots Help Files

- Install and load library

```
> install.packages("ggplot2") # Install new library  
> library(ggplot2) # Load library
```

- Visualise documentation for a function or library

```
> ?mean # or help(mean)  
> help("PCA", package = "FactoMineR")  
> example(mean)
```

- Load preloaded datasets

```
> data(cars)  
> library(help = "datasets")  
> View(cars)
```

R: Data Frames

A data frame is a table of data in R:

- each row = one individual (or observation),
- each column = one variable (or attribute),
- columns can be of different types (numeric, text, factor, etc.).

```
> class(cars)  
> is.data.frame(cars)
```

```
> df = data.frame(  
  Nom = c("Alice", "Bob", "Clara"),  
  Age = c(23, 25, 22),  
  Sexe = c("F", "M", "F")  
)
```

R: Manipulate Data Frames

```
> head(cars)

> summary(cars)

> head(mtcars)

> names(mtcars) # Show column names

> mtcars$hp <- NULL # Delete a column

> mtcars <- mtcars[-2,] # Delete a row

> mtcars$new_var <- 1:nrow(mtcars) # Add a column
```

R: Read csv

- Example of csv file

```
Name; City; Sallary; Year
Alpha; Paris; 22000; 2023
Beta; Lyon; 69500; 2023
Gamma; Marseille; 33400; 2023
Delta; Paris; 12000; 2024
```

- Read csv file

```
data <- read.csv("ventes.csv", sep = ";", dec = ".", header = TRUE, row.names = 1)
```

Delimiter
(eg. , or \t or ;)

Decimal
separator
(. or ,)

Whether the first
line is columns
names

Use first column
as index

TP1: R basics

1. Charger un dataset intégré
 1. Chargez le jeu de données **mtcars**.
 2. Visualiser les données sous forme de table.
 3. Affichez les 5 premières lignes et le résumé des variables.
2. Modifier le dataset
 1. Supprimez la colonne drat.
 2. Ajoutez une colonne prix avec des valeurs aléatoires entre 10000 et 40000.
 3. Supprimez la première ligne du tableau.
3. Ajouter une nouvelle ligne
 1. Créez une ligne avec vos propres valeurs et ajoutez-la à la fin.
4. Sauvegarder et réimporter
 1. Sauvegardez votre table CSV en utilisant write.csv (utiliser ?write.csv pour afficher l'aide.)
 2. Réimportez-la avec read.csv() et vérifiez les données.

Dimensionality

Reduction

using



PCA using FactoMineR

- FactoMineR is an R package (developed by the team of François Husson) dedicated to multivariate exploratory data analysis. The main goal is to simplify complex multivariate analyses and make them accessible and interpretable.
- It provides functions for the most common multivariate methods, such as:
 - ◆ Principal Component Analysis (**PCA**)
 - ◆ Correspondence Analysis (**CA**)
 - ◆ Multiple Correspondence Analysis (**MCA**)
 - ◆ Hierarchical Clustering (**HCPC**)
 - ◆ and several extensions (**MFA**, **MFAmix**, etc.).
- FactoMineR automatically produces:
 - ◆ Tables of eigenvalues, contributions, and squared cosines (\cos^2)
 - ◆ Graphical outputs (individuals, variables, biplots)
 - ◆ Interpretation aids (which variables/individuals influence each axis)

PCA using FactoMineR

- Load Library

```
> install.packages(c("FactoMineR", "factoextra"))  
> library(FactoMineR)  
> library(factoextra)
```

- Run PCA on USArrests dataset

```
> res.pca <- PCA(USArrests)
```




- Basic plots

```
> plot(res.pca, choix = "var") # Plot of variables  
> plot(res.pca, choix = "ind") # Plot of individuals
```


PCA using FactoMineR and factoextra

- Use factoextra for better visualization

```
fviz_eig(res.pca, addlabels = TRUE, ylim = c(0, 50)) # Scree plot
fviz_pca_var(res.pca, col.var = "contrib")          # Variables
fviz_pca_ind(res.pca, col.ind = "cos2", gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"))
fviz_pca_biplot(res.pca, repel = TRUE)              # Biplot
```



PCA using FactoMine: Variables plot interpretation



- ▶ Each arrow represents a quantitative variable.
- ▶ The **direction** and **length** of an arrow show how much that variable contributes to the **axes**. Longer arrows → better represented on the plane (higher \cos^2).
- ▶ Variables close to the same axis are the ones that define that component the most.
- ▶ The angle between arrows indicates **correlation** between variables:
 - Small angle (close arrows) → strong positive correlation.
 - Opposite directions (180°) → strong negative correlation.
 - Perpendicular (90°) → very weak correlation.

Objectif. Réaliser une ACP sur les données decathlon. Les données portent sur des athlètes ayant participé à un décathlon (10 épreuves d'athlétisme). Chaque ligne correspond à un athlète, chaque colonne à une épreuve : 100m, longueur, poids, hauteur, 400m, 110m haies, disque, perche, javelot et 1500m. L'objectif est de comprendre comment ces épreuves sont reliées entre elles, quelles dimensions principales structurent la performance globale.

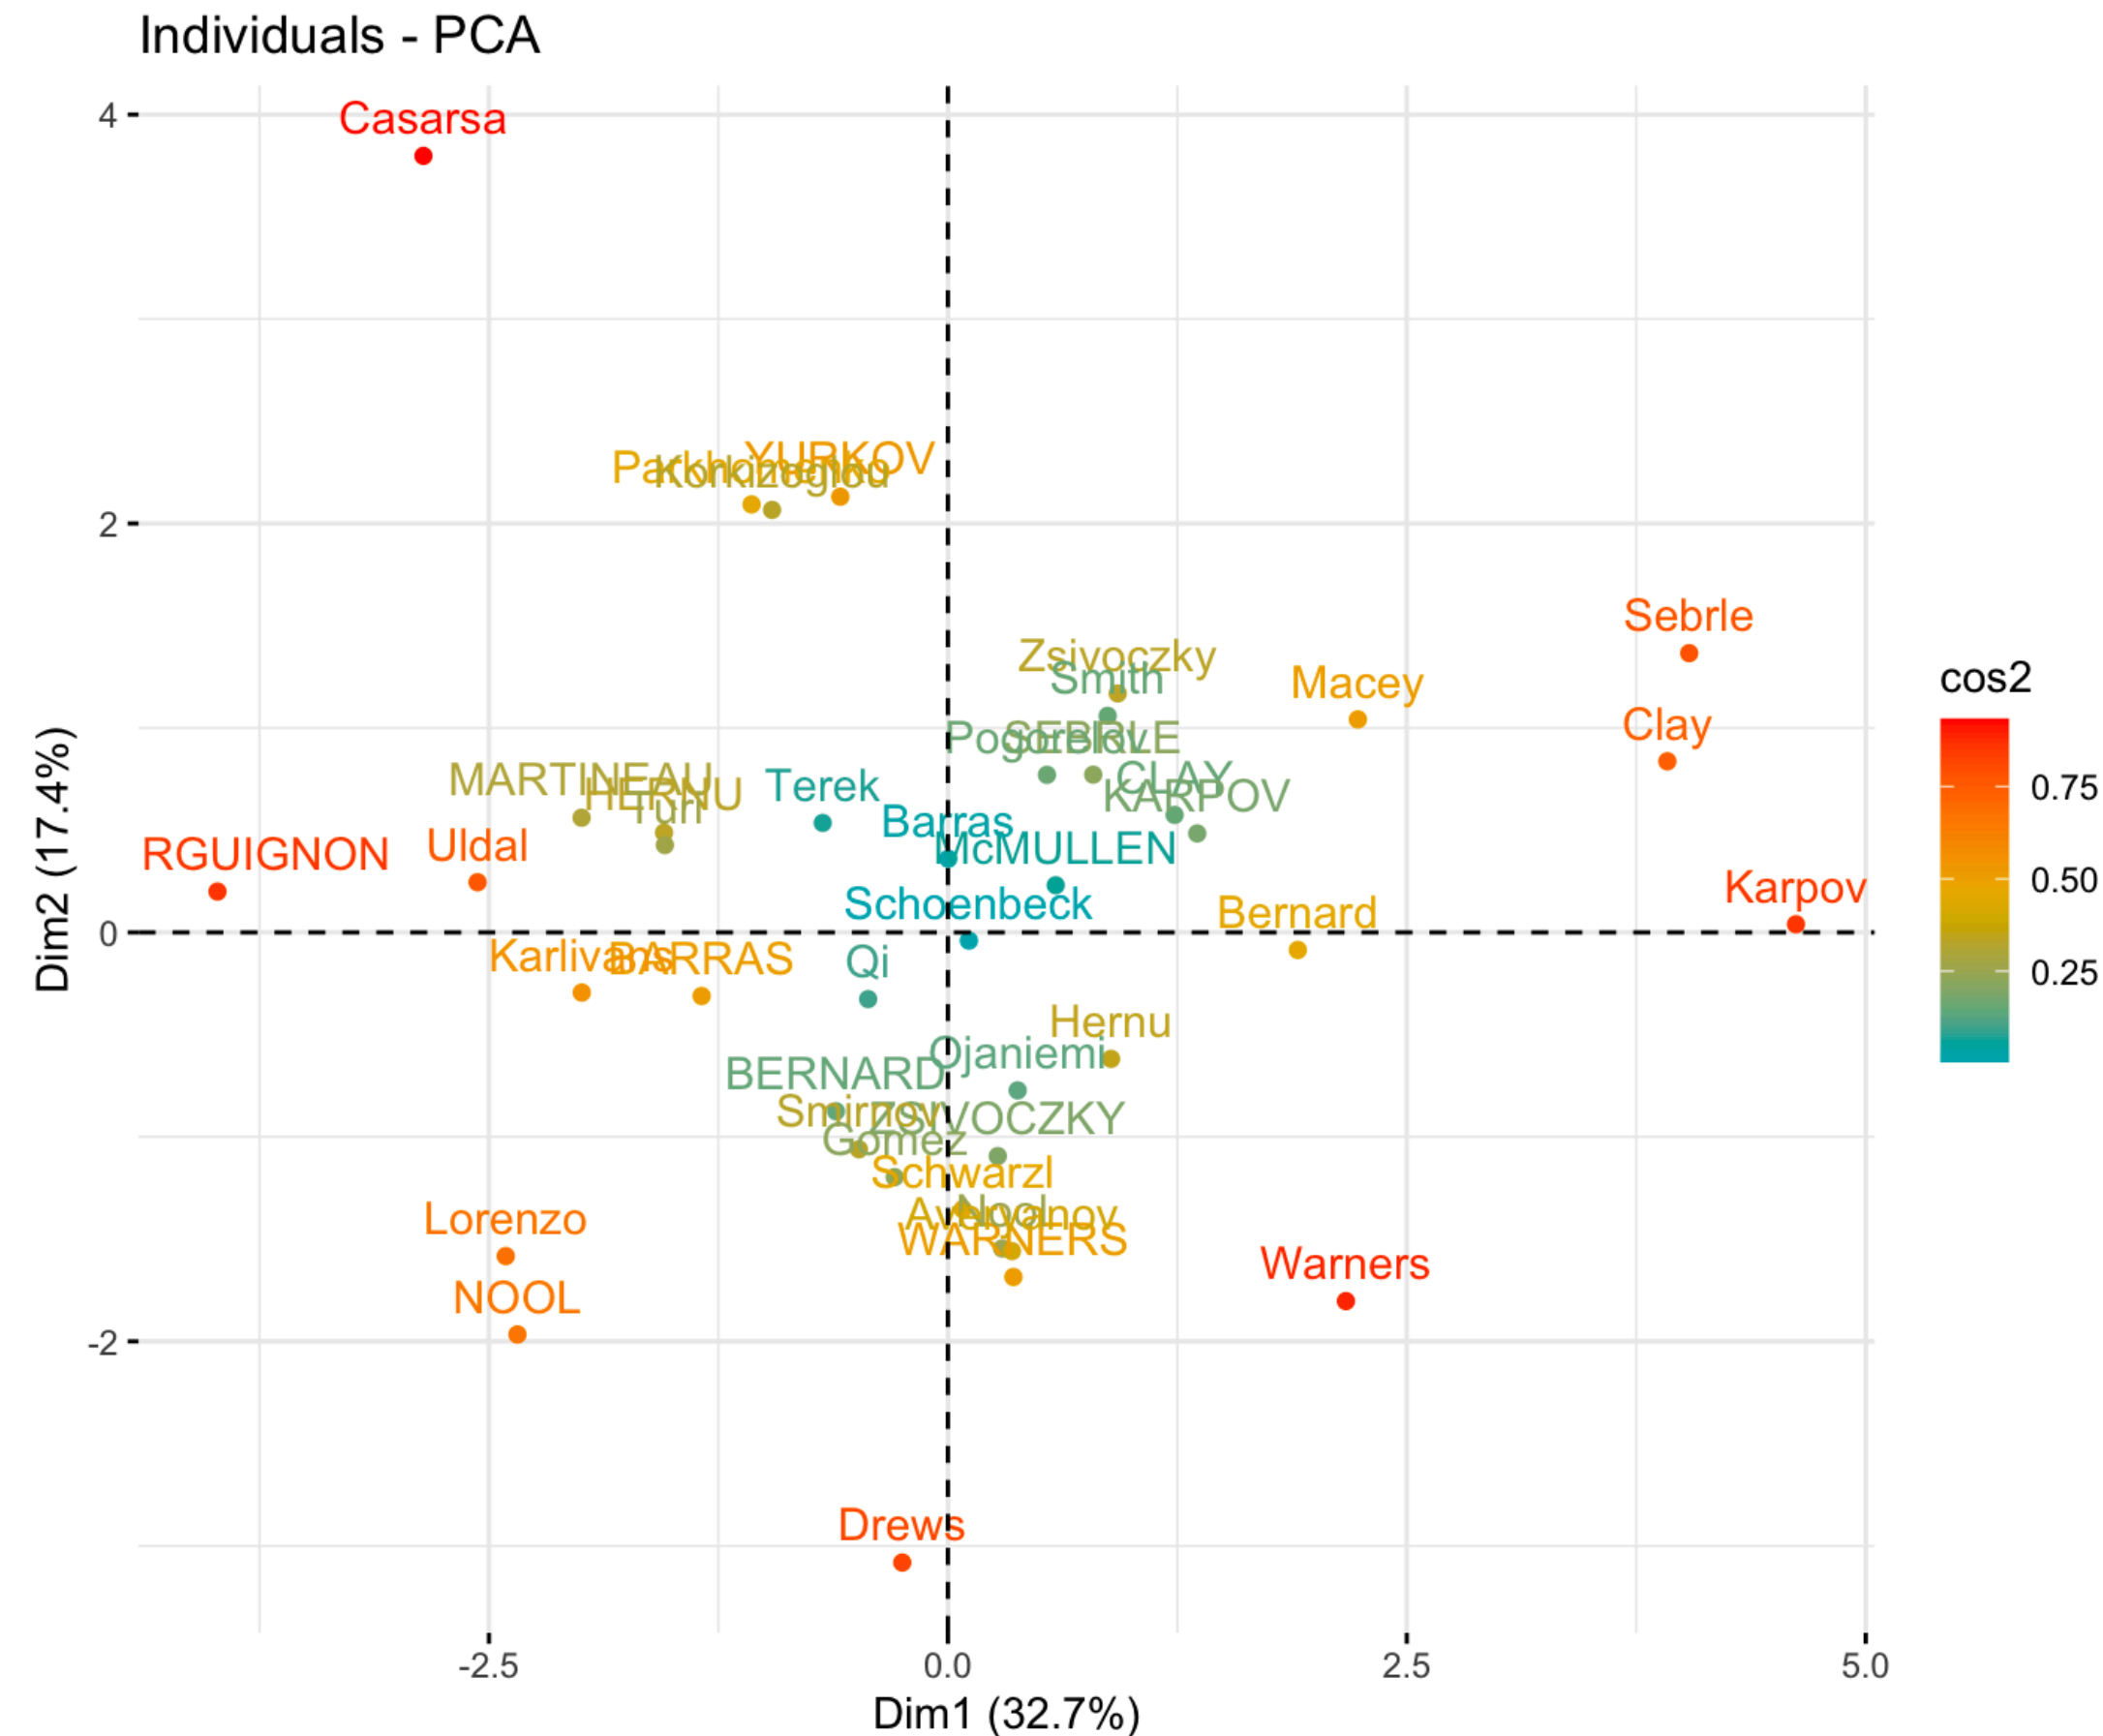
1. Préparation et exploration

- Sélectionner les variables quantitatives correspondant aux dix épreuves.
- Examiner la structure et le résumé statistique du jeu de données.
- Expliquer brièvement le type de variables et les unités mesurées.

2. Réaliser une ACP

- Effectuer une ACP sur les dix épreuves uniquement et considérer le reste en variables supplémentaires.
- Afficher le cercle des corrélations des variables avec FactoMineR avec factoextra.
- Identifier les variables fortement corrélées, ceux qui sont bien représentées, et ceux qui contribuent le plus aux deux premiers axes.
- Interpréter les deux premiers axes : que semble représenter le premier axe ? Que semble représenter le deuxième axe ?
- Repérer les grands groupes de variables et les types de performances qu'ils décrivent.

PCA using FactoMineR: Variables plot



- ▶ Each point represents an individual (here: an athlete).
- ▶ The **position** of each individual is determined by their scores (coordinates) on the principal components (Dim1, Dim2, etc.).
- ▶ Individuals that are **close** to each other on the plot have **similar** performance profiles across all variables.
- ▶ The axes (Dim1, Dim2) represent **underlying dimensions** (combinations of variables that summarize performance).
- ▶ The color scale (\cos^2) shows the quality of representation:
 - High \cos^2 → the individual is well represented on this plane.
 - Low \cos^2 → less well represented; the individual's pattern **may appear on another dimension**.
- ▶ Individuals far from the origin are more extreme or distinctive (very high or very low scores).

Après avoir étudié les **relations entre variables**, on cherche maintenant à comprendre **comment les athlètes se répartissent** dans l'espace défini par les deux premières dimensions de l'ACP.

1. Générer le plot des individus (plan 1–2).
2. Observer la répartition générale des athlètes :
 - Le nuage est-il homogène ou structuré ?
 - Observe-t-on des groupes distincts ou des valeurs extrêmes ?
3. Identifier les individus les plus éloignés du centre
 - Que signifie leur position dans le plan ?
 - Quelle information donne la distance à l'origine ?
4. Repérer les groupes d'athlètes proches les uns des autres :
 - Que peut-on en déduire sur leurs profils de performance ?
 - Quels athlètes semblent partager des caractéristiques communes ?
5. En observant la disposition générale :
 - Comment se distribuent les athlètes le long du premier axe (Dim 1) ?
 - Et le long du second axe (Dim 2) ?